

Data-analyse Opdracht: Eredivisie 2023/2024

Tijdsindicatie: 3 tot 4 uur
Niveau: 2
Domein: Data-analyse met Python

Inleiding

In deze opdracht duik je in de wereld van sportdata-analyse. Je gaat aan de slag met echte wedstrijdgegevens van het Eredivisie-seizoen 2023/2024. Met behulp van de Python-bibliotheek `pandas` leer je hoe je data kunt inladen, opschonen, analyseren en visualiseren. Het doel is om patronen en inzichten te ontdekken die verborgen liggen in de ruwe data. Wie scoort het meest? Is er echt een thuisvoordeel? Aan het einde van deze opdracht kun jij deze vragen beantwoorden met data!

Voorkennis

Voor deze opdracht is basiskennis van Python handig. Je moet weten hoe je:

- Een Google Colab-notebook opent en gebruikt.
- Code in een cel uitvoert.
- Het `Voetbaldata 2023/2024.csv`-bestand uploadt naar je Colab-omgeving.
- Het is handig om voordat je met deze opdracht gebint de [W3Schools: Pandas tutorial](#) te doorlopen.

De Data

Je gebruikt een `.csv`-bestand met data van alle wedstrijden uit het seizoen. Enkele belangrijke kolommen zijn:

- `HomeTeam`: Het thuisteam
- `AwayTeam`: Het uitteam
- `FTHG`: Full Time Home Goals (doelpunten thuisteam na 90 min)
- `FTAG`: Full Time Away Goals (doelpunten uitteam na 90 min)
- `FTR`: Full Time Result (H=Thuiswinst, D=Gelijk, A=Uitwinst)
- `HTHG`: Half Time Home Goals (doelpunten thuisteam bij rust)
- `HTAG`: Half Time Away Goals (doelpunten uitteam bij rust)
- `HTR`: Half Time Result (H=Thuiswinst, D=Gelijk, A=Uitwinst)

Open een nieuw notebook in Google Colab en volg de onderstaande stappen. Veel succes!

Stap 1: Data Inladen en Eerste Inspectie

Doel: Kennismaken met de dataset.

1. Importeer de bibliotheken:

```
1 import pandas as pd
2 import matplotlib.pyplot as plt
```

2. Laad de data in een DataFrame: Vul de code aan om het bestand Voetbaldata_2023/2024.csv in te lezen.

```
1 # Vul de juiste bestandsnaam in de functie aan
2 df = pd.read_csv('...')
```

3. Bekijk de eerste rijen: Gebruik de juiste functie om de eerste 5 rijen van de tabel (df) te tonen.

```
1 # Schrijf hier de code om de eerste 5 rijen te tonen
2 ...
```

4. Krijg een overzicht: Gebruik de juiste functie om een samenvatting van de DataFrame op te vragen.

```
1 # Schrijf hier de code om de info van de DataFrame op te vragen
2 ...
```

Stap 2: Data Opschonen en Voorbereiden

Doel: De data klaarmaken voor analyse.

1. Maak een nieuwe kolom: Om te analyseren hoeveel doelpunten er per wedstrijd zijn gescoord, maak je een nieuwe kolom aan. Vul de code aan om de nieuwe kolom TotaalAantalDoelpunten te maken door de doelpunten van het thuis- (FTHG) en uitteam (FTAG) bij elkaar op te tellen.

```
1 # Maak een nieuwe kolom 'TotaalAantalDoelpunten'
2 # Tel hier de waarden uit de kolommen 'FTHG' en 'FTAG' bij elkaar
  op
3 df['TotaalAantalDoelpunten'] = ...
4
5 # Controleer je werk door de eerste rijen opnieuw te bekijken
6 df.head()
```

Stap 3: Verkennende Analyse - De Eredivisie in Cijfers

Doel: De eerste algemene inzichten uit de data halen.

1. Totaal aantal doelpunten:

```
1 # Vul de juiste kolomnaam in om de som te berekenen
2 totaal_goals = df['...'].sum()
3 print(f"Totaal aantal gescoorde doelpunten in het seizoen: {
    totaal_goals}")
```

2. Gemiddeld aantal doelpunten per wedstrijd:

```
1 # Vul de juiste kolomnaam in om het gemiddelde te berekenen
2 gemiddelde_goals = df['...'].mean()
3 print(f"Gemiddeld aantal doelpunten per wedstrijd: {
    gemiddelde_goals:.2f}")
```

3. Thuisvoordeel:

In de voetballerij wordt vaak gesproken over het 'thuisvoordeel'. Dit betekent dat teams gemiddeld vaker winnen als ze thuis spelen, bijvoorbeeld door steun van het publiek of vertrouwde met het veld. Maar is dat ook echt zo? Met deze stap ga je onderzoeken ****hoe vaak het thuisteam wint, het gelijkspel voorkomt, en het uitteam wint****.

Tip: Kijk eens naar de kolom waarin wordt aangegeven wie er wint.

```
1 # Vul de juiste kolomnaam in en gebruik een geschikte functie om te
    tellen
2 resultaat_verdeling = df['...'].value_counts()
3 print("Verdeling van de wedstrijdresultaten:")
4 print(resultaat_verdeling)
```

Stap 4: Visualiseren van de Resultaten

Doel: Inzichten omzetten in duidelijke grafieken.

Grafieken maken patronen en verschillen in je data zichtbaar die je in een tabel makkelijk over het hoofd ziet. Zo kun je in één oogopslag zien welk resultaat het vaakst voorkomt, of hoeveel wedstrijden meestal veel (of weinig) doelpunten hebben.

1. Maak een cirkeldiagram van de resultaten:

Een cirkeldiagram ('pie chart') laat in één oogopslag zien hoe de verschillende uitslagen verdeeld zijn over alle wedstrijden. Zo ontdek je bijvoorbeeld snel of er vaak een gelijkspel is, of dat het thuisteam meestal wint.

Tip: In pandas kun je van een verdeling makkelijk een cirkeldiagram maken met de `plot()` functie en het argument `kind='pie'`. Bijvoorbeeld: als je een Series `fruit_aantallen` hebt met de aantallen appels, bananen en peren, dan kun je zo'n grafiek maken met:

```
1 fruit_aantallen.plot(kind='pie', autopct='%1.1f%%', title='
    Fruitverdeling')
```

Probeer nu deze techniek zelf toe te passen op de verdeling van de wedstrijdresultaten in jouw data!

```
1 # Maak een cirkeldiagram van de resultaten
2 ....plot(.....)
3
4 plt.ylabel('')
5 plt.show()
```

2. Maak een histogram van het aantal doelpunten:

Een histogram laat zien hoe vaak een bepaald aantal doelpunten in een wedstrijd voorkomt. Hierdoor zie je in één oogopslag of wedstrijden meestal weinig of juist veel doelpunten opleveren.

Tip: In pandas kun je van een kolom met getallen eenvoudig een histogram maken met de `plot()` functie en het argument `kind='hist'`. Bijvoorbeeld: als je een lijst leeftijd hebt met leeftijden van mensen, dan maak je zo'n grafiek met:

```
1 leeftijd.plot(kind='hist', bins=10, title='Leeftijdsverdeling')
```

Probeer nu deze techniek toe te passen op het aantal doelpunten per wedstrijd in jouw data!

```
1 # Maak een histogram van het aantal doelpunten
2 ....plot(.....)
3
4 plt.xlabel("Totaal Aantal Doelpunten")
5 plt.ylabel("Aantal Wedstrijden")
6 plt.show()
```

Eindopdracht: Analyseer Jouw Favoriete Club

Doel: Pas de geleerde technieken toe in een mini-onderzoek naar een specifiek team. Deze eindopdracht wordt beoordeeld met een cijfer.

Kies een team en beantwoord de vragen in je Colab-notebook.

Stappen en Vragen

1. Filter de data:

```
1 # Vervang 'jouw_team' door de exacte naam van je team
2 team_naam = "PSV Eindhoven" # Bijvoorbeeld
3
4 # Schrijf hier de code om de DataFrame te filteren op jouw team
5 df_team = df[...]
6
7 # Toon de eerste rijen van je nieuwe DataFrame om te controleren
8 df_team.head()
9
```

2. **Analyseer de prestaties:** Presteert jouw team beter in thuis- of uitwedstrijden? Onderbouw je antwoord met data.
3. **Analyseer de mentaliteit:** Hoe vaak geeft jouw team een voorsprong bij rust weg? En hoe vaak wordt een achterstand omgebogen?
4. **Visualiseer de resultaten:** Maak een staafdiagram dat laat zien hoe vaak jouw team heeft gewonnen, verloren en gelijkgespeeld.
5. **Conclusie:** Schrijf een korte conclusie (ongeveer 100 woorden) over de prestaties van jouw team.

Beoordelingsmodel

Categorie	0 Punten	1 Punt	2 Punten	3 Punten
Code Structuur & Werking	Code is afwezig of werkt niet.	Poging tot structuur, maar incompleet/foutief.	Code werkt met juiste basisstructuur, kleine onvolkomenheden.	Code is correct, compleet, efficiënt en overzichtelijk.
Dataverwerking & Analyse	Vragen onbeantwoord of data incorrect.	Poging gedaan, maar filters/berekeningen fundamenteel onjuist.	Analyses grotendeels correct, maar met een kleine fout.	Data correct gefilterd, alle berekeningen juist uitgevoerd.
Visualisatie & Conclusie	Grafiek/conclusie ontbreekt.	Grafiek onduidelijk, conclusie afwezig of niet onderbouwd.	Grafiek correct maar niet volledig opgemaakt. Conclusie aanwezig maar zwak onderbouwd.	Grafiek is helder en compleet. Conclusie wordt sterk onderbouwd met data.

Cijferberekening: $\text{Cijfer} = (\text{Totaal aantal punten} / 9) * 9 + 1$